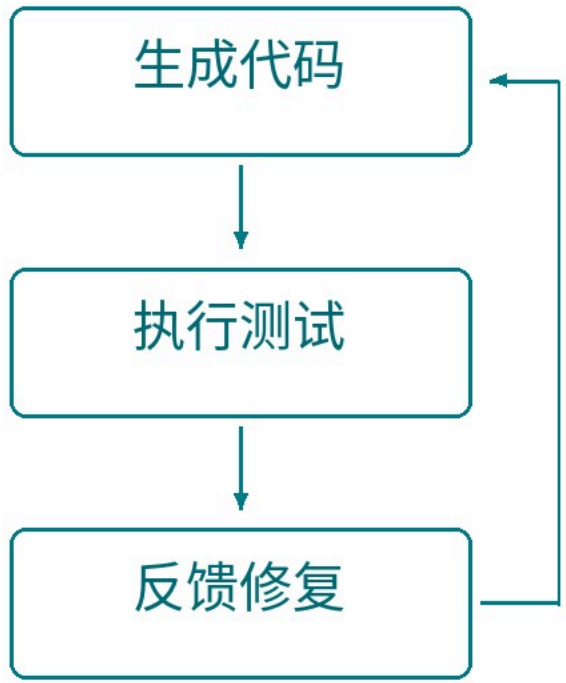
前三周学习与作业汇报

代码生成的
自动测试与反馈修复

模型推理 · 代码助手 · Agent



姜楠翔　23230610

第一周：Qwen 模型推理

- Qwen2.5-1.5B：单次推理 3.622 秒，生成 74 个 token
- 最后层 hidden state：[1, 48, 1536] → [1, 1, 1536]
- 部分数值：0.31055，2.0，0.0，1.58594

第二周：我想解决什么问题

- 已跑通普通回答、流式输出和结构化校验
- 原示例检查了格式和语法，没有执行代码测试
- 我的拓展：自动测试 → 反馈具体错误 → 自动重试

代码改动：校验结果决定是否重试

JSON → 字段 → 语法 → 函数名 → 测试

```
result = validate_text(text, task)
feedback = repair_feedback(result, task)
if feedback and repairs < args.repair:
    repairs, source = repairs + 1, "auto_repair"
```

history：保留错误回答，再追加反馈

fresh：丢弃错误回答，用原任务和反馈重新生成

实验：保留错误回答，还是重新生成？

任务	保留错误回答	丢弃错误回答后重试
正数计数	3 次修复，通过	1 次修复，通过
第二大不同值	3 次修复，失败	2 次修复，通过
游程编码	3 次修复，失败	3 次修复，失败

通过的两项任务分别完成 5/5、7/7 个测试用例。

第三周：Agent 自测与五组实验

自测 14 项全部 PASS；固定任务的正确答案为 94%。

组	模型和解码	status	最终答对
1	1.5B，贪心	ok	否
2	1.5B，采样 T=0.7	ok	否
3	1.5B，采样 T=1.2	too_many_failures	否
4	3B，贪心	max_steps	否
5	7B，贪心	too_many_failures	否

看调用链：问题出在哪一步

- 1.5B：错误路径 → 读取失败 → final 说信息不足
- 3B：读文件 → 算出 94 → 回答没有 final JSON
- 补充文件名和调用示例后，3B、7B 的 4 次运行均答对

这次拓展的结果与不足

- 代码助手增加了测试和自动反馈，减少人工追问
- 重新生成在本组任务中效果更好，游程编码仍失败
- 下一步补严单变量实验，并检查 Agent 的最终答案