逐页中文讲稿

姓名：姜楠翔；学号：23230610。

共 8 页，建议约 4 分 20 秒。无附录，讲稿已写入 PPT 备注。

核心问题：代码生成出错后，如何自动检查并修复？保留错误回答，还是用原任务和错误反馈重新生成更有效？

讲稿补充必要的技术细节，每页只讲一段。表格和代码不必逐行念，正常语速配合指图，控制在课程要求的 3–5 分钟内。

第 1 页：前三周学习与作业汇报

建议 15 秒，累计 0 分 15 秒。

大家好，我是姜楠翔。前三周我做了模型推理、代码助手和 Agent 实验。这次重点汇报一个小拓展：给生成的代码加上测试，再让模型根据错误自动修改。

第 2 页：第一周：Qwen 模型推理

建议 40 秒，累计 0 分 55 秒。

第一周，我用 Transformers 在 GPU 上跑 Qwen 一点五 B。先预热一次，再正式计时，并等待 GPU 完成计算，避免计时偏差。一次推理用了三点六二二秒，生成七十四个新 token，不把输入算进去。我还观察了最后一层的数据：开始处理四十八个输入位置，之后带着缓存，每次只处理一个新位置。不过，模型对缓存的解释不准确，说明跑通和答对还要分开检查。

第 3 页：第二周：我想解决什么问题

建议 30 秒，累计 1 分 25 秒。

第二周，我跑通了普通回答、流式输出和结构化校验。流式就是边生成边显示，结构化则要求按统一的 JSON 格式回答，方便程序读取。但格式和语法正确，不代表代码结果正确。所以我加上测试用例，让程序实际运行代码，失败后自动反馈，不用每次手动追问。

第 4 页：代码改动：校验结果决定是否重试

建议 40 秒，累计 2 分 5 秒。

这里主要加了两部分。第一部分是校验：检查 JSON、字段、语法和函数名，再执行测试，比较返回值和类型。测试放在独立进程里，超过五秒就停止，避免卡住。第二部分是修复：把具体错误发给模型，最多重试三次。我比较两种方式：history 保留错误回答继续改；fresh 丢弃错误回答，只给原任务和错误提示，让模型重新写。

第 5 页：实验：保留错误回答，还是重新生成？

建议 35 秒，累计 2 分 40 秒。

实验用了三个任务，模型和生成设置保持一致，只比较两种修复方式。保留错误回答时，正数计数修复三次才通过，另外两项失败。重新生成后，正数计数一次修复通过，第二大不同值两次修复通过，分别通过五个和七个测试。游程编码仍然失败。因此在这组实验里，重新生成修好了更多任务，也减少了重试，但还需要更多任务验证。

第 6 页：第三周：Agent 自测与五组实验

建议 35 秒，累计 3 分 15 秒。

第三周，我让 Agent 读取测试报告，再用工具计算通过率。报告有四十七项通过、三项失败，答案应是百分之九十四。程序的十四项自测全通过，但换模型大小和生成方式后，五组实验最终都没答对。两组虽然显示 ok，也只是正常结束。另外，第三组到第四组同时改了模型和采样方式，这部分还需要补成严格的单变量对照。

第 7 页：看调用链：问题出在哪一步

建议 45 秒，累计 4 分 0 秒。

我查看了两条调用链，也就是模型每一步说了什么、调用了什么、工具返回了什么。一点五 B 把路径写错，工具没读到文件，最后却正常结束。三 B 读到了文件，计算器也算出九十四，但它没按要求输出 final JSON，程序不接受，最后用完了步数。我据此补充文件名、收尾规则和调用示例。三 B、七 B 在两版新提示下的四次运行都答对了，但一点五 B 仍会写错计算器参数。

第 8 页：这次拓展的结果与不足

建议 20 秒，累计 4 分 20 秒。

这次拓展把代码检查和错误反馈连了起来，重新生成在这几个任务中效果更好。Agent 实验也说明，调用工具不代表一定做对。接下来会补严对照实验，并检查最终答案，而不是只看是否正常结束。谢谢大

家。